

# 인공지능을 사용한 가정용 전력 사용량 예측

신민혁\*, 김민호\*, 이세훈\*, 이상기\*, 강병권\*\*

## Predicting Home Power Usage Using Artificial Intelligence

Min Hyuck Shin\*, Min Ho Kim\*, Seh Un Lee\*, Sang Gi Lee\*, Beong-Gwon Kang\*\*

### 요 약

본 연구에서는 2010년부터 2018년까지의 전력 데이터, 인구수, 평균 전력 요금을 이용해 LSTM(Long Short-Term Memory) 모델로 전력 소비량을 예측하는 방법을 제안하였다. 분석 결과, 전력 데이터와 인구수 간의 높은 상관관계를 확인하였으며, 이를 바탕으로 전력 소비량 예측에 필요한 입력 변수로 선택하여 모델을 학습시켰다. LSTM 모델은 시계열 데이터 처리에 효과적이며, 높은 예측 정확도를 달성하였다.

### Abstract

This study proposes a method for predicting electricity consumption using an LSTM (Long Short-Term Memory) model, leveraging electricity data, population statistics, and average electricity rates from 2010 to 2018. The analysis confirms a strong correlation among these variables, which were selected as input features for the model. The LSTM model, effective in processing time series data, achieved high prediction accuracy. The findings are expected to contribute to electricity consumption forecasting and support policy development in the energy sector.

### Key words

LSTM, electricity consumption, time series prediction, correlation analysis, forecasting

## 1. 서 론

최근 소득증가, 기후변화 등 많은 요인으로 에너지 소비는 급격한 증가추세에 있다. 특히 전력소비는 계절적 요인 없이도 지속적으로 증가하고 있으며, 그중에서도 가정용 전력소비는 에너지 다소비 계층의 증가에 따라 꾸준히 증가하고 있다[1]. 이러한 현상은 지난해 러시아-우크라이나 전쟁으로 인해 에너지 시장이 매우 불안정해졌기 때문에[2], 전

력 소비 예측의 중요성을 더욱 부각시키며, 정확한 예측은 에너지 관리에 필수적인 요소 중 하나가 된다. 가정용 전력 소비량에 중요한 영향을 미치는 요소는 인구수와 평균 전력 요금의 변동이다. 최근 이러한 요소들을 인공지능 알고리즘에 적용하여 전력 사용량을 예측하는 모델들이 다수 출시되고 있다. 본 연구에서는 과거의 데이터 요소를 기반으로 미래 전력 사용량을 예측하는 인공지능을 제안한다. 특히, 기존의 인공지능과는 다르게 시계열을 다룰

\*순천향대학교 정보통신학과 학부과정 smh3140ko@sch.ac.kr

\*\*순천향대학교 정보통신공학과 교수 bgkang@sch.ac.kr

※ 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 2024년도 SW중심대학사업의 연구 결과로 수행되었음  
\*(2021-0-01399)

수 있는 모델인 LSTM(Long Short-Term Memory)을 활용하여 적은 변수와 전처리로 정확도를 높이고, 모델 훈련 소요시간을 줄여 효율성 또한 향상시키는 것에 중점을 두었다.

## II. 본론

### II - 1. 데이터 수집 및 전처리

본 연구논문에서 사용된 데이터는 전력거래량, 인구수, 평균 전력 요금으로, 전력데이터 개방 포털 시스템에서 수집되었다. 2010년부터 2018년까지의 데이터는 학습데이터로 활용되었고, 2019년부터 2021년까지의 데이터는 테스트데이터로 활용되었다. 수집된 데이터에 대한 상관관계 분석을 수행한 결과, 가장 높은 상관관계를 나타내는 변수는 인구수로 확인되었으며, 이를 본 연구의 예측 변수로 포함하였다. [그림 1]은 이러한 상관관계 분석 결과를 시각적으로 나타내고 있다.




그림 1. 히트맵  
Fig. 1. Heatmap

데이터 간의 상관관계를 분석하고, 데이터를 서로 합친 후 전력값과 인구수 변수에 대한 scaling 전처리를 진행하였다. scaling 알고리즘은 정규화를 적용시켜 주었으며, feature\_range는 0.1로 처리하였다. 이 경우, 단위가 큰 전력과 인구수는 [표1.]과 같이 0과 1사이의 값으로 조정되며 모델 학습 효과가 있기 때문에 효율성을 높일 수 있는 전처리중

하나이다.

표 1. scaling 된 데이터의 비교

Table 1. Comparison scalped data

| 날짜      | 전력소비량    |            |
|---------|----------|------------|
|         | 전        | 후          |
| 2010/01 | 12610307 | 0.00528171 |
| 2010/02 | 12624529 | 0.00979318 |
| 2010/03 | 12636677 | 0.01693697 |
| 2010/04 | 12655913 | 0.0233666  |
| 2010/05 | 12673226 | 0.03097943 |

### II - 2. 모델 선정 및 학습

전처리된 데이터를 학습하기에 앞서 데이터에 적합한 모델을 선정하였다. 본 논문에서 사용되는 데이터는 시계열 데이터이므로, 그에 맞게 가장 보편적으로 시계열 데이터에 사용할 수 있는 LSTM(Long Short-Term Memory) 모델과 구글에서 2017년에 발표한 모델인 트랜스포머(transformer) 모델을 사용하며 비교한다. MAPE(Mean Absolute Percentage Error)는 회귀모델의 학습 정도를 확인할 때 사용되는 평가 지표이다. MAPE는 다음과 같은 공식으로 정의된다.

$$MAPE = \frac{100}{n} \times \sum_{i=1}^n \left| \frac{Y_i - \hat{Y}_i}{Y_i} \right| \quad (1)$$

식(1)에서  $Y_i$ 는 실제 값이며  $\hat{Y}_i$ 는 예측값이다.

다음으로 손실률(Loss)은 실제 정답과 모델이 예측한 값 사이의 차이이다. 손실이 커질수록 오류가 커진다고 볼 수 있다. 본 논문에서 활용된 모델의 손실함수는 MSE(Mean Squared Error)를 사용하였다. MSE(Mean Squared Error, 평균제곱오차)는 이름에서 알 수 있듯이 오차를 제곱한 값의 평균이다. 이는 아래의 수식으로 정의된다.

$$MSE = \frac{1}{N} \sum_{i=1}^N (pred_i - target_i)^2 \quad (2)$$

식(2)에서 pred는 예측값이며 target은 실제값이다.

표 2. Transformer와 LSTM의 지표

Table 2. Transformer and LSTM Indicators

|      | LSTM  | Transformer |
|------|-------|-------------|
| MAPE | 0.26% | 0.0002      |
| Loss | 0.94% | 0.0103      |

표2에서 실험 결과 각 모델의 정확도와 손실률을 최종적으로 나타낸다. 위 실험 결과 전체적인 결과는 Transformer보다 LSTM의 성능이 탁월함을 알수 있고 최종적인 모델은 LSTM을 사용하여 구현하는 것을 제안한다. 결정된 LSTM 모델의 파라미터를 조정하며 [표 3.] 과 같이 실험을 진행하였다. [표 3.]의 MAPE는 각각의 기준으로 모델을 적용했을 때 결과이다.

표 3. 훈련 결과

Table 3. Result

| 실험 | epochs | batch size | optimizer | MAPE |
|----|--------|------------|-----------|------|
| 1  | 100    | 8          | adam      | 0.35 |
| 2  | 100    | 8          | SGD       | 0.06 |
| 3  | 100    | 16         | adam      | 0.67 |
| 4  | 100    | 16         | SGD       | 1.21 |
| 5  | 200    | 8          | adam      | 0.38 |
| 6  | 200    | 8          | SGD       | 0.08 |
| 7  | 200    | 16         | adam      | 0.33 |
| 8  | 200    | 16         | SGD       | 0.25 |

위 실험의 결과, 실험 2 가 가장 좋은 결과를 나타냄을 알 수 있었다. 이를 기반으로 일반화된 모델을 만들었고, 그에 따른 테스트 데이터인 2019년부터 2021년의 데이터를 예측하였다. 그에 따른 그래프는 [그림 2.]에 나타난다.




그림 2. 예측데이터와 실제데이터

Fig 2. Predicted and Real Data

### III. 결론 및 향후 과제

본 연구에서는 2010년부터 2018년까지 축적된 가정용 전력 소비 데이터를 학습용으로 사용하여, LSTM의 우수한 시계열 예측 성능을 통해 2019년 이후의 전력 소비량을 높은 정확도의 예측 결과를 얻을 수 있었으며, 이는 본 모델이 전력 소비 패턴을 성공적으로 학습했음을 보여준다. 이러한 예측 결과는 가정용 전력 수요 변동을 미리 파악함으로써 에너지 자원의 효율적 배분과 미래 전력 수급 정책에 기여할 수 있는 가능성을 가졌다. 특히 사계절이 존재하는 우리나라의 계절적 변동성이나 장기적인 트렌드를 예측하는데 있어 LSTM 모델의 우수한 가능성과 적합성을 확인하였다. 결과적으로 이러한 모델을 활용함으로써 향후 미래의 전력 소비를 예측·대비할 수 있다는 가능성을 보인다.

본 연구는 가정용 전력 소비 패턴에 한정하여 모델을 학습했으므로, 대한민국 전체 전력 소비 패턴을 포괄하는 데 한계가 있다. 보다 완전한 예측을 위해서는 상업용 및 산업용을 포함한 다양한 계약 유형별 전력 소비 패턴을 학습한 모델이 추가적으로 필요하다. 또한, 본 연구에서 구축된 모델은 인구수 및 과거 전력 소비 패턴에 크게 의존하고 있어, 전쟁이나 질병과 같은 예외적 사건에 대한 예측 탄력성이 낮다는 한계를 가진다. 이러한 한계는 비정상적 상황에서 모델의 예측 성능 저하를 야기할 수 있다. 더불어, 본 연구에서 사용된 모델은 월 단위 예측을 수행하므로, 전력 소모의 실시간 변동에 대한 즉각적 대응이 어려운 한계가 있다. 향후 연구에서는 예측 단위를 주 단위 또는 일 단위로 세분화하고 외부 충격 변수들을 추가함으로써 전력 소모 패턴의 미세한 변동을 보다 정확히 반영하고자 한다. 이를 통해 피크 전력을 기저 전력으로 대체하거나 피크 전력 부족에 사전 대비하는 효과를 기대할 수 있으며, 궁극적으로 전력 수급의 안정성 제고와 효율적인 에너지 관리 전략 수립에 기여할 수 있을 것으로 사료된다.

## 참 고 문 헌

- [1] 김민경. (2013). “서울시 가정용 전력소비의 변화요인과 저감방안. “ 정책리포트,(149), 1-20.
- [2] 김창식, 김영민. (2023). 에너지위기 대응과 국내 수요관리 정책 현황. 전기저널,, 22-27.